PROYECTO:

Análisis de Datos Clínicos en Pacientes Diabéticos

1. Introducción

Cuando se plantea analizar la readmisión hospitalaria en pacientes con diabetes, la intuición inicial sugiere que la edad avanzada, la comorbilidad y la carga terapéutica deberían concentrar el mayor riesgo. Con esa expectativa comenzó este proyecto.

Sin embargo, el análisis del conjunto de datos, más de 100.000 ingresos hospitalarios en EE. UU., mostró desde fases tempranas que el fenómeno era menos evidente de lo esperado. Aunque el volumen de registros era amplio, la información disponible presentaba limitaciones relevantes que fueron haciéndose más visibles a medida que avanzaba la investigación.

Este trabajo parte, por tanto, de una pregunta abierta: ¿Qué patrón puede identificarse realmente, con los datos disponibles, en la readmisión precoz de pacientes diabéticos hospitalizados?

2. Preparación y transformación del dataset

El primer contacto con el dataset no fue conceptual, sino operativo: cargar el archivo CSV original y verificar su dimensión real. Con más de 100.000 registros, cualquier decisión de limpieza tendría un impacto estructural en el análisis posterior.

2.1 Primer hallazgo: valores faltantes no explícitos

El conteo inicial de nulos resultó insuficiente. El dataset no solo contenía `NaN`, sino también codificaciones como `"?"` o `"Unknown/Invalid"`. Tras su recodificación como valores faltantes reales (`np.nan`), se hizo evidente que la ausencia de información era más amplia de lo que parecía inicialmente.

Desde esta fase comenzó a percibirse una limitación estructural: no todos los vacíos eran meramente técnicos; algunos podían corresponder a información clínica no registrada.

2.2 Eliminación de variables con alta proporción de nulos

Se eliminaron las variables:

- weight
- max_glu_serum
- A1Cresult

- medical_specialty
- payer_code

El criterio fue estrictamente cuantitativo: todas presentaban más del 80% de valores ausentes.

Si bien variables como A1Cresult o max_glu_serum son clínicamente relevantes en el contexto de la diabetes, su nivel de incompletitud hacía inviable su incorporación analítica sin introducir un sesgo significativo o recurrir a imputaciones especulativas. Mantenerlas habría reducido drásticamente el tamaño muestral efectivo o generado una estructura altamente fragmentada.

Desde una perspectiva de ciencia de datos aplicada, se prioriza la estabilidad estructural del dataset y la consistencia estadística del análisis frente a la conservación de variables con escasa representatividad real.

2.3 Imputación en variables categóricas

Las variables race, diag_1, diag_2, diag_3 y gender presentaban valores ausentes que, de eliminarse, habrían reducido de forma relevante el número de registros disponibles.

Se decidió imputarlos como "Unknown" para mantener el tamaño muestral y evitar perder información útil en otras variables. No se optó por imputaciones más complejas porque, en este contexto, podrían haber introducido supuestos no verificables.

La categoría "Unknown" permite conservar los registros y, al mismo tiempo, dejar explícita la ausencia de información. Fue una decisión práctica orientada a mantener consistencia y estabilidad en el análisis.

2.4 Transformación de la edad

La edad estaba codificada en rangos ([60–70), [70–80), etc.). Se transformó cada intervalo en su punto medio para permitir análisis numéricos (correlaciones, umbrales ≥65 años e integración en modelos).

La conversión facilitó la modelización, pero introdujo una simplificación: asumir homogeneidad dentro de cada rango.

2.5 Construcción de variables derivadas

Se crearon tres variables clave:

- elderly (≥65 años)
- polypharmacy (≥10 medicamentos)
- readmitted_30d (binaria)

El umbral de polifarmacia (≥10) se definió de forma deliberadamente exigente, buscando capturar perfiles de alta complejidad farmacológica.

En esta etapa aún existía una expectativa implícita: que la complejidad terapéutica aumentaría el riesgo de readmisión. Con el avance del análisis, esa relación no resultó tan contundente como cabía anticipar.

2.6 Mapeo de variables administrativas

Se transformaron identificadores numéricos en categorías interpretables (tipo de admisión, tipo de alta, fuente de ingreso). Este paso permitió que el análisis pasará de una lectura puramente técnica a una interpretación hospitalaria más comprensible.

2.7 Agrupación de diagnósticos ICD-9

Los códigos ICD-9 se agruparon en categorías amplias (circulatorio, respiratorio, digestivo, diabetes, lesión, neoplasias, otros).

La decisión respondió a criterios de manejabilidad en el análisis exploratorio. Sin embargo, esta agregación pudo diluir subgrupos clínicos específicos, limitando la capacidad de detectar patrones más finos.

3. Análisis Exploratorio de Datos

El análisis exploratorio permitió identificar patrones iniciales y, al mismo tiempo, confirmar que el fenómeno de la readmisión no respondía a un único determinante evidente. Los gráficos no mostraron resultados contundentes, pero sí aportaron señales consistentes que orientaron el enfoque posterior.

3.1 Distribución de la estancia hospitalaria

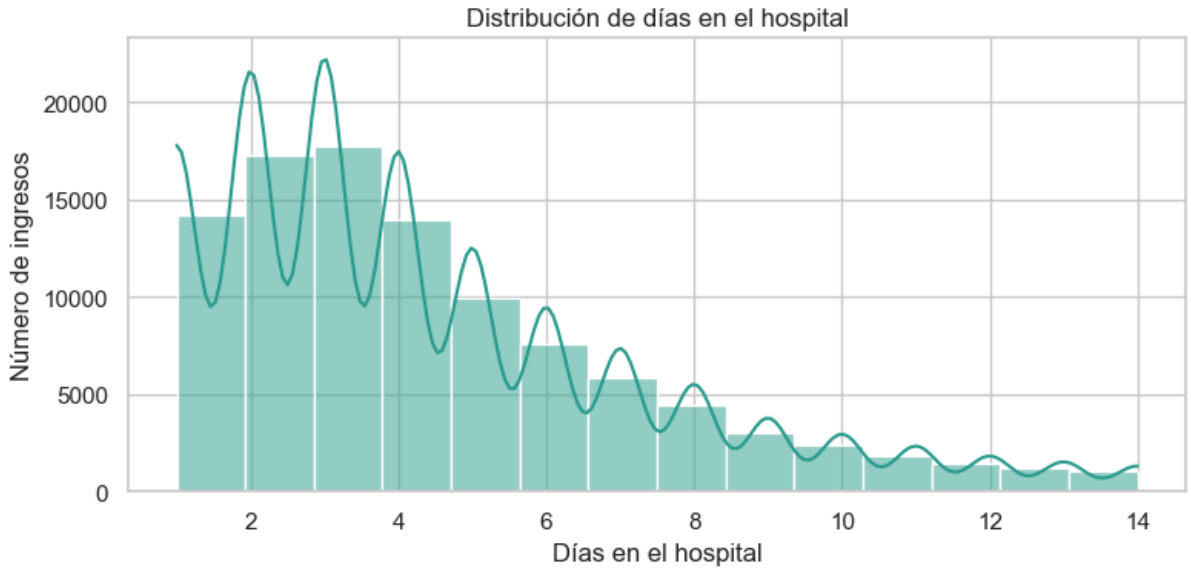

El histograma de time_in_hospital mostró una concentración clara entre 2 y 6 días, con una distribución asimétrica a la derecha.

Esto confirma que la mayoría de los ingresos asociados a diabetes no son prolongados. Sin embargo, la cola derecha revela la existencia de un subgrupo con estancias significativamente mayores (hasta 14 días), lo que sugiere mayor complejidad clínica o complicaciones asociadas.

Este hallazgo desplazó parcialmente el foco: más que identificar únicamente quién reingresa, comenzó a cobrar importancia entender qué caracteriza a los pacientes con mayor carga asistencial durante el ingreso inicial.

3.2 Número de medicamentos y días de hospitalización

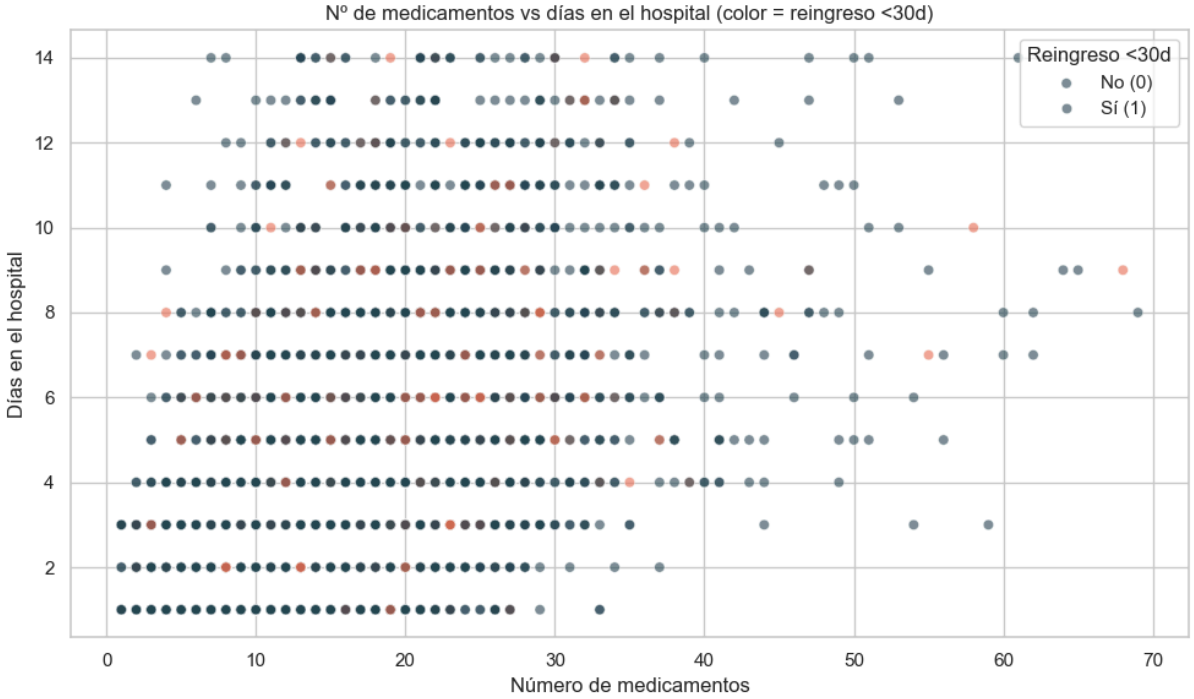

El gráfico de dispersión entre Número de medicamentos y Días en el hospital mostró una relación positiva visible: a mayor número de medicamentos, mayor duración de estancia.

Aunque no se trata de una relación perfectamente lineal, el patrón es consistente y respalda la hipótesis de que la complejidad farmacológica se asocia a mayor carga asistencial.

Aquí comenzó a consolidarse una idea clave: la acumulación de complejidad parece más relevante que cualquier variable aislada.

3.3 Insulina y readmisión

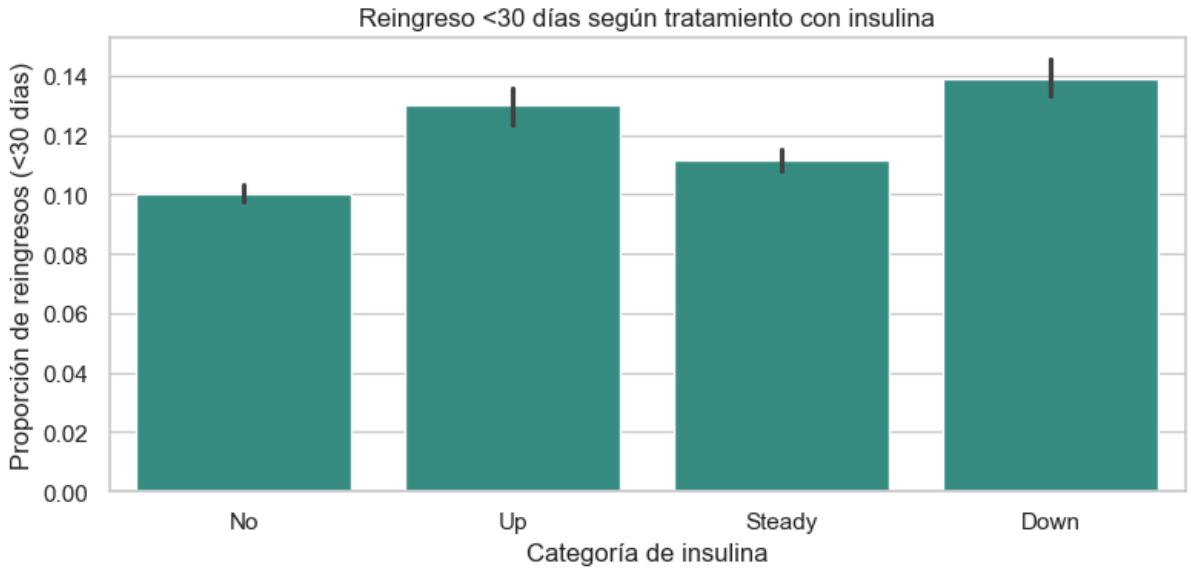

El análisis por categoría de tratamiento con insulina mostró una mayor proporción de readmisión en los grupos con cambios terapéuticos (“Up” y “Down”) respecto a los pacientes sin cambios.

El patrón sugiere que no es simplemente el uso de insulina lo relevante, sino la modificación del tratamiento, posiblemente asociada a situaciones de inestabilidad metabólica.

Este resultado introdujo una dimensión dinámica en el análisis: las transiciones terapéuticas pueden reflejar mayor vulnerabilidad clínica.

3.4 Correlaciones entre variables clínicas

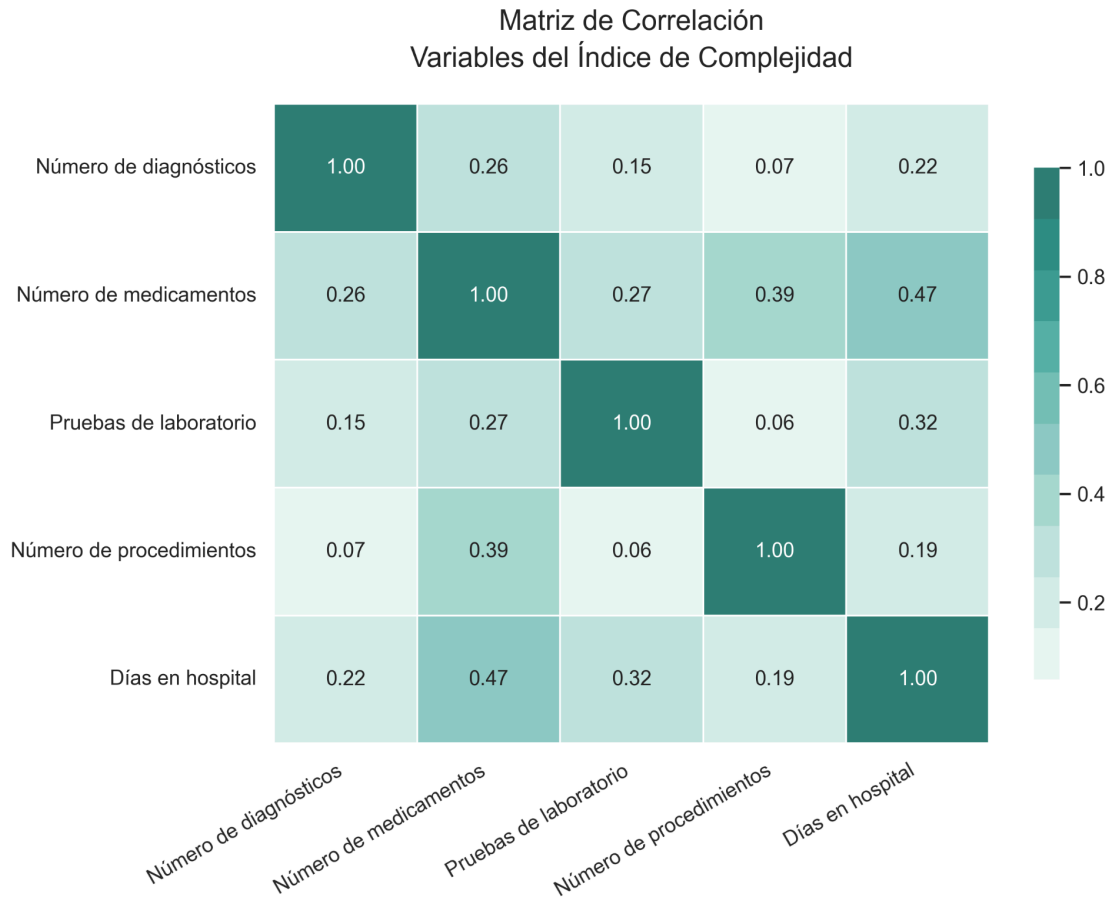

La matriz de correlación confirmó que no existían asociaciones extremadamente altas entre las variables principales.

La correlación más destacada fue entre número de medicamentos y días de hospitalización (~0.47), seguida de relaciones moderadas con pruebas de laboratorio.

No aparece un “factor dominante” que explique por sí solo el fenómeno. Esto reforzó la necesidad de considerar el carácter multifactorial de la readmisión.

3.5 Índice de complejidad clínica

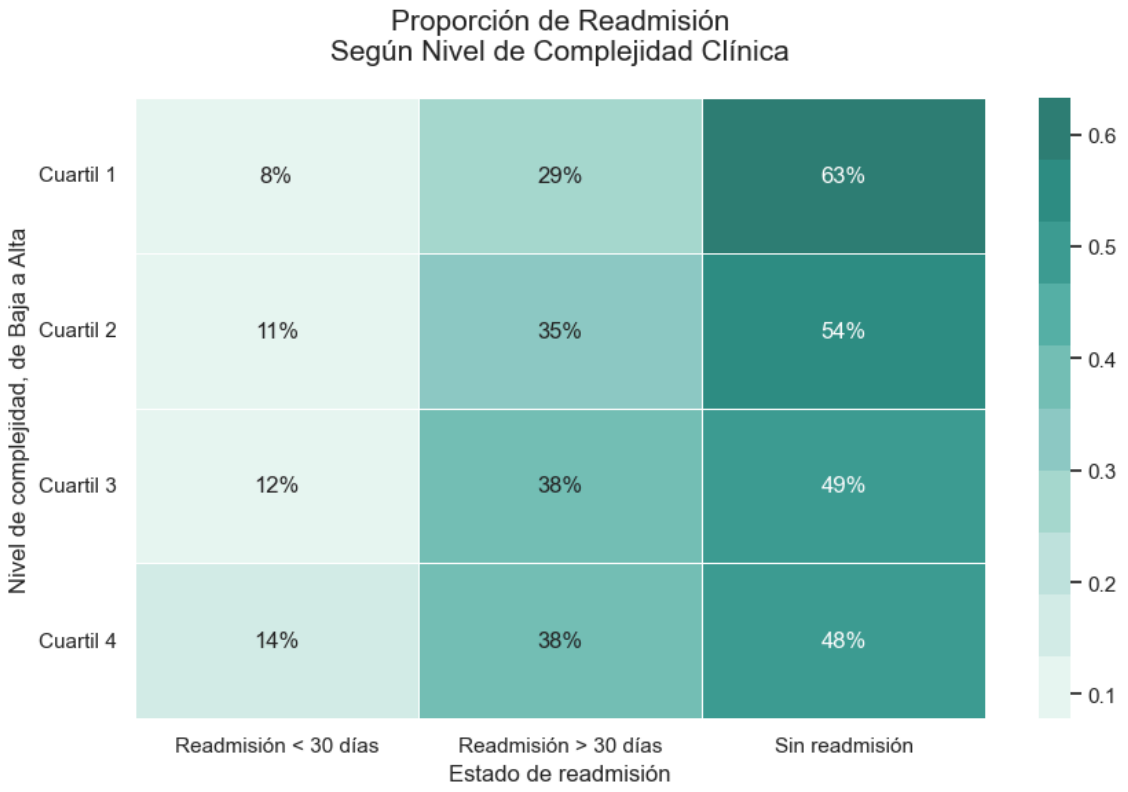

Ante la ausencia de un predictor único claro, se construyó un índice compuesto sumando:

- Número de diagnósticos
- Número de medicamentos
- Ingresos previos
- Visitas a urgencias
- Días de hospitalización

La creación del índice respondió a una necesidad analítica: sintetizar la complejidad acumulativa en una métrica única.

Al dividir el índice en cuartiles y cruzarlo con el estado de readmisión, se observó un patrón progresivo: a mayor nivel de complejidad acumulada, mayor proporción de readmisión <30 días.

Aunque el incremento no es abrupto, sí muestra una tendencia coherente. Este fue el primer resultado que ofreció una señal estructural más clara dentro de las limitaciones del dataset.

4. Ingeniería de variables e índices clínicos

Tras el análisis exploratorio, el proyecto alcanzó un punto de transición. Los resultados iniciales mostraron que:

- La edad no era un determinante estructural.
- La complejidad acumulativa tenía mayor peso explicativo.
- Los cambios en la insulina presentaban un patrón consistente de mayor readmisión.

En este contexto surgió una pregunta más específica:
¿Puede identificarse un subgrupo clínico concreto con mayor riesgo de readmisión precoz?

El objetivo dejó de ser descriptivo y pasó a ser constructivo: generar un indicador clínicamente interpretable.

4.1 De variables aisladas a combinaciones clínicas

El EDA mostró que ni la “insulina activa” por sí sola ni el “cambio terapéutico” de forma independiente explicaban completamente el fenómeno. Sin embargo, la combinación de ambas variables parecía concentrar mayor proporción de reingresos.

Decidí entonces construir una variable combinada con dos dimensiones:

- Insulina activa (sí/no)
- Cambio terapéutico (sí/no)

Esto generó cuatro grupos clínicos diferenciados. El grupo “con insulina y con cambio” emergió como el perfil con mayor proporción de readmisión.

La decisión metodológica fue clara: analizar interacciones clínicamente plausibles en lugar de limitarse a efectos individuales.

4.2 Cuantificación mediante Odds Ratio

Para evaluar la magnitud del efecto se calculó una odds ratio global.

Resultado aproximado: OR ≈ 1,21.

Se trata de un efecto moderado, no de gran magnitud. Sin embargo, su consistencia justificó continuar la exploración. En un contexto multifactorial, efectos discretos pero estables pueden tener relevancia clínica.

La interpretación fue prudente: no se trata de un marcador determinante, sino de una señal con coherencia interna.

4.3 Control por complejidad basal

Surgió entonces una cuestión metodológica necesaria:

¿Podría este efecto deberse simplemente a que estos pacientes eran globalmente más complejos?

Para evaluarlo, se realizó una estratificación por niveles de complejidad basal y se recalculó la OR en cada estrato.

La asociación se mantuvo >1 en los distintos niveles, lo que sugiere que el efecto no era exclusivamente atribuible a mayor gravedad acumulada. Aunque no puede descartarse confusión residual, el patrón mostró estabilidad.

4.4 Simplificación frente a exhaustividad

El marcador “insulina activa + cambio terapéutico” tiene ventajas claras:

- Es interpretable.
- Es reproducible.
- Es operativamente identificable en un entorno hospitalario.

4.5 Del índice acumulativo al marcador focalizado

El índice global de complejidad permitía describir un patrón general: a mayor carga acumulativa, mayor proporción de readmisión.

Sin embargo, el marcador terapéutico aportaba una hipótesis clínica concreta:
la readmisión precoz podría asociarse a momentos de inestabilidad terapéutica más que a un estado estático de gravedad.

Este desplazamiento conceptual marcó una maduración del proyecto: del análisis estructural hacia una interpretación clínica plausible, siempre dentro de las limitaciones informativas del dataset.

5. Modelado predictivo y evaluación

Tras el análisis exploratorio y la construcción de indicadores clínicos, el proyecto dio un paso decisivo: evaluar capacidad predictiva.

La pregunta dejó de ser descriptiva y pasó a ser operativa:

¿Hasta qué punto las variables disponibles permiten discriminar entre pacientes con y sin readmisión precoz?

5.1 Expectativas iniciales

El tamaño muestral y la variedad de variables clínicas permitían anticipar una capacidad discriminativa al menos moderada. Sin embargo, el análisis previo ya mostraba un fenómeno multifactorial, sin correlaciones fuertes ni un predictor dominante evidente.

Esto hacía prever que el rendimiento del modelo difícilmente sería elevado.

5.2 Construcción del modelo

Se integraron variables como:

- Edad numérica
- Número de medicamentos
- Ingresos previos (inpatient, emergency)
- Tiempo de hospitalización
- Polifarmacia
- Indicadores de cambio terapéutico
- Uso de insulina

Se utilizó un modelo supervisado tipo **Random Forest**, buscando capturar interacciones no lineales sin imponer supuestos estrictos de linealidad. La elección priorizó capacidad discriminativa frente a simplicidad paramétrica.

5.3 Resultado principal: AUC ≈ 0,64

El modelo alcanzó un AUC aproximado de 0,64 (IC95% ~0,63–0,65).

Este valor indica capacidad discriminativa moderada. No es suficiente para decisiones clínicas individuales, pero confirma la existencia de señal predictiva dentro del dataset.

El resultado fue coherente con lo observado en el EDA: el fenómeno contiene información, pero no de alta intensidad discriminativa.

5.4 Peso dominante de los ingresos previos

El análisis de importancia de variables mostró que los ingresos previos eran el predictor con mayor peso relativo.

Esto planteó una cuestión metodológica relevante:
¿El modelo predice readmisión o simplemente identifica pacientes con alta recurrencia asistencial?

Para evaluarlo, se reconstruyó el modelo excluyendo dicha variable.

5.5 Modelo sin ingresos previos: AUC ≈ 0,58

Al eliminar los ingresos previos, el AUC descendió a aproximadamente 0,58 (IC95% ~0,57–0,60).

La reducción fue clara. Sin esa información, el rendimiento se aproxima a una discriminación limitada.

Esto indica que la trayectoria asistencial reciente es estructuralmente central en la predicción. Otras variables aportan señal, pero ninguna compensa su ausencia.

5.6 Ajuste conceptual

El modelo obligó a revisar la expectativa inicial.

No fueron la edad ni la gravedad aislada los ejes dominantes.
Fue la recurrencia previa la variable más determinante.

La readmisión precoz parece reflejar un patrón de vulnerabilidad acumulada dentro del sistema sanitario más que un evento puntual derivado únicamente del ingreso actual.

5.7 Limitaciones del modelado

- Ausencia de variables socioeconómicas.
- Eliminación de indicadores metabólicos clave (HbA1c) por alta proporción de nulos.
- Falta de estructura longitudinal completa.
- No se realizó validación externa.
- Evaluación limitada de calibración.

El AUC moderado sugiere que el fenómeno no es plenamente capturable con variables administrativas y clínicas básicas.

Síntesis de la fase de modelado

- Capacidad discriminativa moderada (AUC ~0,64).
- Los ingresos previos fueron el predictor dominante.
- Sin ellos, el rendimiento descendió a ~0,58.
- El patrón está más ligado a trayectoria asistencial que a gravedad estática.

Este fue el punto de mayor ajuste conceptual del proyecto: abandonar la búsqueda de un predictor clínico fuerte aislado y aceptar la naturaleza estructural y acumulativa del fenómeno.

Conclusiones finales

El proyecto no culmina con un modelo de alta precisión, sino con una comprensión más sólida y realista del fenómeno.

La readmisión precoz no depende de un único factor dominante. La complejidad acumulativa y la trayectoria asistencial previa desempeñan un papel central, mientras que los cambios terapéuticos en pacientes con insulina pueden señalar momentos de mayor vulnerabilidad clínica.

Más allá de los resultados cuantitativos, el valor del trabajo reside en el proceso: pasar de hipótesis intuitivas a evidencia matizada, ajustar expectativas frente a los límites del dato y aprender a interpretar señales moderadas dentro de fenómenos complejos.

El proyecto permitió consolidar competencias clave en análisis de datos clínicos: limpieza estructurada, construcción de variables, evaluación crítica de modelos y lectura prudente de métricas predictivas.

En coherencia con el caso de negocio, se identificaron patrones relevantes en el manejo hospitalario de pacientes diabéticos y se establecieron bases analíticas útiles para futuras investigaciones o mejoras en la práctica asistencial.